毕设项目中期进展报告（代码核对版）

> 说明：本报告已按项目**实际代码与文档**核对后撰写，重点依据：
>
> - `src/edane.py`
> - `src/edane_full_pipeline.py`
> - `src/prepare_datasets.py`
> - `README.md` 与 `docs/` 下相关文档

一、任务要求（依据任务书与调研）

课题为**高效的超大规模动态属性网络表征方法研究**，核心目标包括：

1. 设计并实现可用于动态属性网络的高效嵌入方法；
2. 在网络结构/属性变化时支持增量更新，减少全量重训练开销；
3. 建立可复现实验流程，完成节点分类、链路预测、重构等指标评估；
4. 在工程上兼顾计算效率与存储开销，支撑后续论文写作与答辩材料产出。

二、任务实现方案分解（与当前代码一致）

（1）算法核心模块实现（`src/edane.py`）

当前 EDANE 代码实现了以下模块：

- **初始化建模**：稀疏随机投影初始化 + 显式迭代优化（`fit()` 内调用 `_compute_structure_embedding()`）。
- **属性表征**：`_compute_attribute_embedding()` 生成属性嵌入。
- **融合策略**：
  - 支持结构/属性融合开关（`use_attr_fusion`）；
  - 支持双曲融合或欧氏融合（`use_hyperbolic_fusion`）；
  - 融合门控含可训练参数（`_train_fusion_gate()`）。
- **增量更新**：`apply_updates()` 支持
  - 节点增加/删除（删除为软删除逻辑）；
  - 边增加/删除；
  - 属性更新；
  - 并以受影响节点及一跳邻域进行局部更新。
- **压缩模块**：支持 int8 量化（`quantize`）与可选二值化（`binary_quantize`），并输出压缩比和误差。

（2）实验流水线与评估（`src/edane_full_pipeline.py`）

端到端流水线已实现：

1. 数据读取与快照构建（支持 synthetic 与 file）；
2. 模型训练与动态更新（EDANE / DANE / DTFormer 三种模型）；

3. 分类评估（`logreg` 或 `centroid`）；
4. 链路预测指标（AUC/AP）与重构 AUC；
5. 实验产物导出：`summary.json`、`metrics_per_snapshot.csv`、`metrics_curves.svg`、embedding 文件等。

补充：

- 提供 `--no-inc` 消融（每快照全量重训）；
- 提供 `--no-attr`、`--no-hyperbolic` 消融（EDANE 专用）；
- 支持 `--eval-protocol repeated_stratified` 等评估协议。

（3）数据构建与大规模可跑性（`src/prepare_datasets.py` + pipeline 流式读取）

- `prepare_datasets.py` 支持 OAG 压缩包转换为统一 CSV（`edges/features/labels`，可选 `attr_updates`）。
- `edane_full_pipeline.py` 的 file 模式支持流式读取、时间分桶、分区文件等机制：
  - `iter_csv_dict()` 流式扫描；
  - `build_graph_from_files_streaming()` 分阶段构图；
  - 支持 `--partition-dir`、`--node-selection-mode`、`--time-quantile-sample` 等参数。

这部分说明当前工程重点已从“仅小规模验证”扩展到“面向大规模数据的可跑通能力”。

三、目前已完成工作与应用技术

（1）核心算法实现进展

已完成 EDANE 主流程与关键模块编码，具备“初始化—更新—融合—压缩”的完整链路。当前实现技术栈以 NumPy/SciPy 为主，支持可选 torch dense 后端（`--backend torch`）。

（2）对比基线与实验统一化

代码中已接入并可运行：

- `edane`（本方法）
- `dane`（`src/dane.py`）
- `dtformer`（`src/dtformer.py`）

并在同一流水线下统一评估、统一输出，便于横向对比与论文整理。

（3）评估结果沉淀方式

每次实验输出可直接用于论文图表与附录复现说明，包括：

- `summary.json`（最终指标、耗时、配置）；
- `metrics_per_snapshot.csv`（逐快照）；
- `metrics_curves.svg`（趋势图）；
- `final_embedding.npy` 与量化副本。

（4）工程与文档

项目文档已形成较完整体系（快速上手、算法说明、流水线用法、全量运行建议、基线说明等），支撑中后期写作与复现实验。

四、当前进度与整体计划匹配情况

对照调研报告中阶段规划：

- 调研与技术路线阶段：已完成；
- 算法与系统实现阶段：核心功能已完成并可运行；
- 实验分析阶段：已完成基础评估链路，正在持续扩展更系统实验矩阵；
- 论文写作阶段：具备进入主写条件（已有稳定实验输出与图表）。

综合判断：当前进度与中期节点要求匹配，工程完成度满足“中期可验证”标准。

五、存在问题与解决措施（按代码现状）

1. **全量规模下资源约束仍明显**
    - 虽已进行流式与分桶改造，但训练阶段仍受邻接与嵌入常驻内存影响。
    - 计划通过高内存环境与渐进放量策略补齐全量实验。
2. **基线同构性问题**
    - DANE/DTFormer 在本项目中采用统一评估适配口径，后续论文将明确说明“适配实现边界”。
3. **实验矩阵较大**
    - 参数维度较多（快照、维度、更新率、量化等），需进一步规范化批处理脚本与结果归档。

六、后期计划

1. 完成阶段化实验矩阵（更新率、消融、参数敏感性）并稳定复现；
2. 形成可直接入文的主结果表与消融表；
3. 完成论文方法与实验章节写作，统一术语与图表口径；
4. 补齐答辩材料（问题定义、创新点、性能对比、局限与展望）。

七、中期总结与自我评价

目前已完成从“方案设计”到“代码落地”再到“统一评估输出”的关键闭环。项目已具备可复现实验能力，并形成了对中后期论文写作有直接支撑的工程基础。下一阶段重点将转向结果强化与论文表达优化。

自我评分：A-（完成度高于80%，后续可按期完成）

附：本次“严格按代码核对”的关键事实

- EDANE 的增量更新入口为 `apply_updates()`，并非仅文档描述；
- 量化/二值化与误差统计在代码中已有字段与实现；
- 流水线实际支持三模型并统一评估导出；
- file 模式的数据处理已包含流式读取与分桶机制；
- 可运行参数及消融开关均在命令行解析器中可见。